

Otokodlayıcı Tabanlı Sistem Aracılığıyla ECG Sinyallerinden Atriyal Fibrilasyon Tespiti

Detection of Atrial Fibrillation from ECG Signals Using an Autoencoder-Based Approach

1. Emre ALAYBEYOĞLU
Bilgisayar Mühendisliği
Eskişehir Osmangazi Üniversitesi
Eskişehir/Türkiye
emrealaybeyoglu01@gmail.com

2. Şevval Ayça ÇERENÇE
Bilgisayar Mühendisliği
Eskişehir Osmangazi Üniversitesi
Eskişehir/Türkiye
aycacerence@gmail.com

Özetçe— Bu çalışmada, elektrokardiyogram sinyalleri üzerinden atriyal fibrilasyonun denetimsiz yöntemlerle tespiti amacıyla 4.826.817 parametrelili, bir boyutlu evrişimli otokodlayıcı mimarisi tasarlanmış ve değerlendirilmiştir. Atriyal fibrilasyon, kalp ritmindeki morfolojik sapmalarla tanınan ve zamanında teşhis edilemediğinde inme ile kalp yetmezliği gibi hayati komplikasyonlara yol açan yaygın bir aritmidir. Geleneksel denetimli modellerin yüksek miktarda etiketli veri gerektirmesi ve giyilebilir cihazlardan elde edilen kayıtlardaki yoğun gürültü bileşenleri, mevcut teşhis sistemlerinin pratikte etkinliğini kısıtlamaktadır. Bu engelleri aşmak amacıyla, 400 Hz örnekleme hızında kaydedilmiş 10 saniyelik segmentlerden oluşan 20.000 sinyallik büyük ölçekli bir veri seti kullanılmıştır. Model, sinyal başına Z-skoru normalizasyonu ve beş katmanlı evrişimli kodlayıcı yapısıyla her sinyal 64 boyutlu bir gizli temsile sıkıştırılmaktadır. Yalnızca sağlıklı ve etiketsiz veriler üzerinden eğitilen model, patolojik sinyallerde yüksek bir yeniden oluşturma hatası üreterek anomali tespiti gerçekleştirmektedir. Kırk üçüncü eğitim döneminde erken durdurma ile tamamlanan süreçte elde edilen bulgular; atriyal fibrilasyon sinyallerindeki ortalama yeniden inşa hatasının 0,1533 olduğunu ve normal sinyallere kıyasla 2,73 kat daha yüksek seyrettiğini ortaya koymaktadır. Tamamen denetimsiz bir yaklaşımla ulaşılan 0,7714'lük AUC skoru, önerilen yöntemin etiket bağımsız bir teşhis altyapısı olarak dijital sağlık sistemlerine entegre edilme potansiyelini doğrulamaktadır.

Anahtar Kelimeler — atriyal fibrilasyon; ECG sinyalleri; otokodlayıcılar; anomali tespiti; derin öğrenme; biyomedikal sinyal işleme

Abstract—In this study, a one-dimensional convolutional autoencoder architecture with 4,826,817 parameters was designed and evaluated for the unsupervised detection of atrial fibrillation from electrocardiogram signals. Atrial fibrillation is a common arrhythmia characterized by morphological deviations in heart rhythm, leading to life-threatening complications such as stroke and heart failure when not diagnosed in a timely manner. The requirement for large amounts of labeled data in traditional supervised models and the presence of heavy noise components in recordings obtained from wearable devices limit the practical effectiveness of current diagnostic systems. To overcome these

obstacles, a large-scale dataset consisting of 20,000 signals composed of 10-second segments recorded at a 400 Hz sampling rate was utilized. The model compresses each signal into a 64-dimensional latent representation using per-signal Z-score normalization and a five-layer convolutional encoder structure. Trained exclusively on healthy and unlabeled data, the model performs anomaly detection by producing a high reconstruction error in pathological signals. The training process, completed with early stopping at the 43rd epoch, revealed that the average reconstruction error for atrial fibrillation signals was 0.1533, which is 2.73 times higher than that of normal signals. An AUC score of 0.7714, achieved through a completely unsupervised approach, confirms the potential of the proposed method to be integrated into digital health systems as a label-independent diagnostic infrastructure.

Keywords — atrial fibrillation; ECG signals; autoencoder; anomaly detection; deep learning; biomedical signal processing.

I. GİRİŞ (INTRODUCTION)

Atriyal fibrilasyon (AF), kalp ritminin morfolojik açıdan düzensizleşmesiyle kendini gösteren ve küresel ölçekte en sık karşılaşılan kardiyak aritmilerin başında gelmektedir. Bu rahatsızlık, vaktinde teşhis edilemediği takdirde inme, kalp yetmezliği ve kardiyovasküler kaynaklı ölüm riskini ciddi oranda artırmaktadır [2], [3]. Dünya genelinde milyonlarca insanı etkileyen bu sağlık sorununun hızlı, ekonomik ve yüksek doğrulukla tespit edilebilmesi modern tıbbın öncelikli hedeflerinden biri haline gelmiştir. Geleneksel tanı süreçlerinde uzman hekimlerin elektrokardiyogram (EKG) sinyallerini manuel olarak incelemesi esas alınsa da, bu yöntem özellikle uzun süreli izleme verilerinin analizinde hem aşırı zaman alıcıdır hem de insan hatasına açık bir yapı sergilemektedir [6]. Giyilebilir teknolojilerin yaygınlaşmasıyla birlikte ortaya çıkan devasa veri hacmi, manuel analizi imkansız kılınmış; bu durum sürekli izleme ihtiyacını karşılayabilecek otomatik ve ölçeklenebilir teşhis sistemlerinin geliştirilmesini zorunlu hale getirmiştir [8].

Literatürdeki mevcut derin öğrenme çözümlerinin büyük bir kısmı, yüksek kaliteli ve uzmanlar tarafından titizlikle etiketlenmiş veri setlerine ihtiyaç duymaktadır [4], [5]. Ancak klinik uygulamalarda ve giyilebilir cihazlardan elde edilen ham verilerin çoğu etiketsizdir ve yoğun gürültü bileşenleri barındırmaktadır. Denetimli (supervised) öğrenme yaklaşımları, yüksek etiketleme maliyetleri ve veri setlerindeki sınıf dengesizlikleri nedeniyle bu tür gerçek dünya senaryolarında yetersiz kalabilmektedir. Bu eksiklikleri gidermek adına hazırlanan bu çalışmada, 400 Hz örnekleme hızına sahip EKG kayıtlarını kullanan bir boyutlu evrişimli otokodlayıcı (1D-CAE) mimarisi önerilmektedir [10].

Projenin temel akademik katkısı, modelin sadece sağlıklı ve etiketsiz veriler üzerinden normal kalp ritmi karakteristiklerini öğrenmesini sağlamak ve patolojik sinyalleri yüksek yeniden oluşturma hatası (reconstruction error) üzerinden tespit ederek etiket bağımlılığını ortadan kaldırmaktır. Bu yaklaşım, gürültülü sinyallerde bile etkili sonuçlar verebilen, düşük maliyetli ve otomatik bir yapay zeka altyapısı sunarak AF'nin erken teşhis süreçlerine dijital bir çözüm desteği sağlamayı hedeflemektedir.

II. İLGİLİ ÇALIŞMALAR (RELATED WORK)

Literatürde EKG sinyalleri üzerinden aritmi tespiti, derin öğrenme yöntemlerinin gelişimiyle birlikte önemli bir ivme kazanmıştır. İlk dönem çalışmalarda Kiranyaz ve ark. [2], evrişimli sinir ağlarının (CNN) hastaya özel EKG sınıflandırmasındaki başarısını ortaya koyarken; Hannun ve ark. [3] ile Rajpurkar ve ark. [4], çok katmanlı derin mimarilerin ve ResNet yapılarının uzman kardiyolog seviyesinde tanı koyabildiğini kanıtlamıştır. Bu çalışmaların ortak noktası, geniş ölçekli ve titizlikle etiketlenmiş veri setlerine ihtiyaç duyan denetimli (supervised) yaklaşımlara dayanmalarıdır. Öte yandan Isin ve Ozdalgi [8], AlexNet gibi klasik evrişimli mimarilerin EKG üzerindeki etkinliğini inceleyerek derin öğrenmenin bu alandaki potansiyelini desteklemiştir.

Sinyallerin zamansal bağımlılıklarını ve gürültü bileşenlerini ele alan çalışmalarda ise farklı mimari arayışlara gidilmiştir. Faust ve ark. [6], EKG verilerindeki zamansal dizilimleri yakalamak için LSTM ağlarını kullanmış; Chauhan ve Vig [9] ise anomali tespiti için LSTM tabanlı otokodlayıcıların patolojik sinyalleri ayırıştırma yeteneğini göstermiştir. Gürültü giderme noktasında Mao ve ark. [10], "Denoising Autoencoder" (DAE) yapılarını başarıyla uygularken; Zhai ve ark. [5], otokodlayıcıları özellik çıkarımı (feature extraction) aşamasında yardımcı bir araç olarak konumlandırmıştır. Thill ve ark. [11] ise zaman serilerinde zamansal otokodlayıcıların geleneksel istatistiksel yöntemlere üstünlüğünü ortaya koymuştur.


Üretken modellerin tıp alanındaki kullanımı, Schlegl ve ark. tarafından geliştirilen AnoGAN [7] mimarisi ile yeni bir boyut kazanmıştır. Bu çalışma, otokodlayıcı tabanlı anomali tespit sistemleri için temel bir ilham kaynağı olmuştur. Mevcut

literatürdeki çalışmaların çoğu otokodlayıcıları ya bir özellik çıkarıcı ya da gürültü temizleyici olarak kullanırken, bu projede sunulan yaklaşım farklılık göstermektedir. Bu çalışmada, diğer modellerden farklı olarak, bir boyutlu evrişimli otokodlayıcı (1D-CAE) mimarisi doğrudan birincil sınıflandırıcı olarak kurgulanmıştır. Literatürdeki birçok çalışmanın aksine, etiketli veri bağımlılığını minimize eden ve doğrudan "yeniden inşa hatası" (reconstruction error) metriğini temel alan bu denetimsiz yaklaşım, AF tespiti için daha ölçeklenebilir ve düşük maliyetli bir çözüm sunmaktadır.

III. YÖNTEM (METHODOLOGY)

Bu çalışmada, EKG sinyalleri üzerinden atriyal fibrilasyonun (AF) tespiti amacıyla denetimsiz öğrenme prensibiyle çalışan bir boyutlu evrişimli otokodlayıcı (1D-CAE) mimarisi önerilmektedir. Çalışmada kullanılan veriler, Kaggle platformunda sunulan ve 400 Hz örnekleme hızıyla kaydedilmiş 10 saniyelik segmentlerden oluşan kapsamlı bir veri setinden temin edilmiştir [1]. Eğitim süreci için 20.000, performans doğrulaması için ise 10.000 adet örnek kullanılmıştır. Giyilebilir cihazlardan elde edilen sinyallerin genlik varyasyonlarını dengelemek ve modelin morfolojik sapmalara odaklanmasını sağlamak amacıyla, verilere sinyal bazlı Z-skoru (Z-score) normalizasyonu uygulanmıştır. Bu adımda her bir sinyal segmenti, kendi ortalamasından çıkarılıp standart sapmasına bölünerek ortalaması 0 ve standart sapması 1 olan bir dağılıma dönüştürülmüştür. Bu yöntem, geleneksel ölçeklendirme tekniklerine kıyasla sinyal gürültülerine ve aykırı değerlere karşı daha dirençli bir girdi yapısı sunmaktadır.

Sistem mimarisinin çekirdeğini oluşturan 1D-CAE ağı, toplam 4.826.817 eğitilebilir parametre içermekte olup; giriş sinyalini ardışık evrişim katmanlarıyla 64 boyutlu bir gizli uzaya (latent space) sıkıştıran kodlayıcı ve bu temsilden orijinal sinyali yeniden inşa eden simetrik kod çözücü bloklarından meydana gelmektedir.



Şekil 1. Otokodlayıcı tabanlı anormali tespit sisteminin genel mimarisi


Şekil 1'de ayrıntılı olarak görselleştirilen bu mimari, hiyerarşik özellikleri yakalamak adına 5 ardışık evrişim katmanından oluşmakta; her katmanda eğitim kararlılığını artırmak için "Batch Normalization" ve negatif gradyan kaybını önlemek adına "LeakyReLU (0.2)" aktivasyon fonksiyonları kullanılmaktadır. Modelin eğitim sürecinde dışarıdan hazır bir modelin uyarlanması yerine, EKG morfolojisine spesifik özelliklerin sıfırdan yakalanması amacıyla sıfırdan eğitim (training from scratch) stratejisi benimsenmiştir. Ağın yalnızca sağlıklı veri dağılımını öğrenebilmesi için eğitim aşamasında tamamen normal sinüs ritmine sahip kayıtlar kullanılmış; optimizasyon sürecinde ise Adam algoritması ve Ortalama Karesel Hata (MSE) kayıp fonksiyonu tercih edilmiştir.

Modelin eğitim başarısını artırmak için EarlyStopping mekanizmasının yanı sıra, gelişim durduğunda öğrenme oranını otomatik olarak düşüren "ReduceLROnPlateau" callback yapısı kullanılmıştır. Sınıflandırma ve karar aşamasında, test verilerinin yeniden inşa edilmesiyle ortaya çıkan MSE değerleri analiz edilerek istatistiksel bir eşik değeri (threshold) belirlenmektedir. Modelin eğitim sırasında

karşılaşmadığı patolojik (AF) sinyallerin yeniden inşası sırasında ortaya çıkan yüksek hata payı, belirlenen bu eşik değeri ile karşılaştırılmakta ve eşik aşan sinyaller sistem tarafından anormali olarak ayırt edilmektedir. Bu karar mekanizması, etiketli veriye ihtiyaç duymadan AF teşhisinin otomatikleştirilmesine olanak tanımaktadır.

IV. ARA SONUÇLAR (PRELIMINARY RESULTS)

Bu projenin mevcut ara rapor aşamasında, önerilen 1D-CAE mimarisinin kavramsal tasarımı tamamlanmış, sinyal ön işleme adımları gerçekleştirilmiş ve toplam 4.826.817 parametrelili ağın ilk eğitim denemeleri başarıyla sonuçlanmıştır. Çalışmanın temel hipotezi, otokodlayıcı ağının yalnızca sağlıklı kalp ritmi verileriyle eğitilmesi durumunda, atriyal fibrilasyon (AF) içeren sinyallerin morfolojik düzensizlikleri nedeniyle yüksek bir yeniden inşa hatası (reconstruction error) üreteceği yönündedir. Eğitim süreci, modelin aşırı öğrenmesini engellemek amacıyla 43. epoch'ta erken durdurma (early stopping) ile optimum seviyede tamamlanmıştır. Modelin eğitim süresince kaydettiği istikrarlı öğrenme eğrisi ve MSE kayıp değerlerindeki başarılı düşüş Şekil 2'de sunulmaktadır.




Şekil 2. Modelin 43 epoch boyunca eğitim ve doğrulama MSE eğrisi

İlk eğitim denemelerinden elde edilen başarı ölçütleri; modelin normal ritimlerdeki P-dalgası ve QRS kompleksini yüksek sadakatle yeniden oluşturabildiğini, Ortalama Karesel Hata (MSE) değerini ise minimum seviyede tutabildiğini göstermektedir. Buna karşın, AF sinyallerinde karakteristik olarak gözlemlenen P-dalgası kaybı ve kaotik f-dalgaları modelin öğrendiği normal dağılıma uymadığı için, bu patolojik vakalarda hata payı normal sinyallere kıyasla 2,73 katlık belirgin bir artış sergilemiştir (Normal ortalama MSE: 0,0561, AFib ortalama MSE: 0,1533). İki sınıf arasındaki bu istatistiksel ayrışma ve yanlış pozitif oranlarını minimize etmek için 0,0632 olarak belirlenen optimum karar eşik değeri (threshold), Şekil 3'te sunulan hata dağılım histogramında net bir biçimde görülmektedir.



Şekil. 3. Normal ve AF sinyallerinin MSE dağılımı ve belirlenen karar eşik değeri (Threshold=0.063)

Sistemin genel ayırt etme gücünü değerlendirmek için, anormali tespiti doğasına uygun olarak ROC-AUC metriği temel alınmıştır. Şekil 4'te detayları verilen analiz sonucunda model, etiketli veri kullanmadan tamamen denetimsiz bir öğrenme sergilemesine rağmen 0,7714 gibi oldukça başarılı bir sınıflandırma performansı (AUC skoru) elde etmiştir.



Şekil. 4. AF tespiti için oluşturulan ROC eğrisi ve AUC skoru

Geliştirme süreçlerinde elde edilen deneyimler, giyilebilir teknoloji tabanlı EKG verilerindeki yoğun gürültü bileşenlerinin modelin yeniden inşa hassasiyeti üzerinde doğrudan belirleyici olduğunu göstermiştir. Bu gürültü faktörünün sağlıklı sinyallerdeki hata payını yapay olarak yükseltme riski, Şekil 3'te belirlenen dinamik eşik değeri optimizasyonu ile minimize edilmiştir. Ayrıca, geniş ölçekli veri setinin işlenmesi sürecinde karşılaşılan yüksek bellek tüketimi ve işlem yükü gibi donanımsal kısıtlar; EarlyStopping ve verimli batch yönetimi gibi stratejik yaklaşımlarla yönetilmiştir. Mevcut bulgular, 0,7714'lük AUC skoruyla birleştiğinde, sistemin gerçek dünya verilerindeki karmaşıklığa rağmen güçlü bir genelleme yeteneğine sahip olduğunu kanıtlamaktadır.

V. TARTIŞMA (DISCUSSION)

Elde edilen 0,7714'lük AUC skoru ve AF sinyallerindeki 2,73 kat daha yüksek yeniden inşa hatası (MSE), önerilen denetimsiz 1D-CAE mimarisinin etiketli veriye ihtiyaç duymadan patolojik sinyalleri ayırt edebildiğini kanıtlamıştır. Modelin başarısı, sağlıklı sinüs ritmine özgü P-dalgası ve QRS kompleksi morfolojisini hassas bir şekilde öğrenmesinden kaynaklanmaktadır. Ancak, giyilebilir cihazlardan gelen yoğun gürültü bileşenlerinin sağlıklı sinyallerde de hata payını yükselterek "yanlış pozitif" oranını artırması en temel kısıtlama olarak gözlemlenmiştir. Bu durum, anormali tespiti için uygulanan dinamik eşik değeri optimizasyonunun klinik doğruluk ve gürültü toleransı açısından ne kadar kritik olduğunu doğrulamaktadır.

Modelin performansının 0,77 bandında stabilize olmasının temel nedeni, paroksizmal AF vakalarındaki bazı sinyal segmentlerinin zaman zaman normal sinüs ritmine çok yakın morfolojik özellikler sergilemesidir. Sadece yapısal bozulmalara odaklanan mevcut 1D-CAE yapısı, bu tür geçici ritim bozukluklarını ayırt etmekte zorlanabilmektedir; bu da gelecekte zamansal dinamikleri daha iyi yakalayan LSTM tabanlı hibrit mimarilerin gerekliliğini ortaya koymaktadır. Ayrıca, 20.000 örneklilik büyük ölçekli veri setinin işlenmesi sırasında karşılaşılan donanımsal bellek riskleri; sinyal bazlı Z-skoru normalizasyonu, verimli batch yönetimi ve EarlyStopping gibi stratejilerle başarıyla yönetilmiştir.

Sonuç olarak, denetimli modeller literatürde daha yüksek doğruluk oranları sunsa da, önerilen bu denetimsiz yaklaşım etiketleme maliyetini ortadan kaldırması ve yüksek çıkarım (inference) hızıyla öne çıkmaktadır. Modelin düşük hesaplama maliyetiyle çalışabilmesi, bu yöntemin kısıtlı donanım kaynaklarına sahip giyilebilir sağlık teknolojilerine entegrasyonu için ölçeklenebilir, maliyet etkin ve sürdürülebilir bir yapay zeka altyapısı sunduğunu kanıtlamaktadır.

VI. GELECEK ÇALIŞMALAR (FUTURE WORK)

Projenin ilerleyen safhalarında, elde edilen 0.7714'lük AUC skorunu ve teşhis hassasiyetini daha ileriye taşımak amacıyla kapsamlı bir model iyileştirme planı yürütülecektir. Bu süreçte öncelikle, 1D-CAE mimarisi üzerinde sistematik bir hiperparametre optimizasyonu gerçekleştirilecektir. Gizli katman derinliği, darboğaz (latent space) boyutu ve öğrenme oranı gibi kritik parametrelerin farklı kombinasyonları test edilerek; modelin normal kalp ritmini minimum kayıpla, patolojik sinyalleri ise maksimum belirginlikle ayırt etmesi sağlanacaktır.

Mevcut evrişimli yapının ötesine geçilerek, EKG sinyallerinin zamansal dinamiklerini daha hassas yakalayabilen yeni yöntem denemeleri de hedeflenmektedir. Bu kapsamda, LSTM tabanlı otokodlayıcılar ve veri dağılımını daha esnek modelleyebilen Varyasyonel Otokodlayıcı (VAE) mimarileri

geliştirilerek mevcut 1D-CAE modeli ile performans karşılaştırmaları yapılacaktır.

Veri verimliliğini artırmak adına, 19.000 etiketsiz kaydın modele entegrasyonu için gelişmiş bir strateji izlenecektir. Ham verinin doğrudan kullanımı yerine, gürültü seviyesi yüksek verileri eleyen otomatik bir veri temizleme boru hattı (pipeline) inşa edilecektir.

VII. SONUÇ (CONCLUSION)

Bu çalışma kapsamında, giyilebilir cihazlardan elde edilen büyük ölçekli ve etiketsiz EKG verileri üzerinde atriyal fibrilasyon (AF) tespiti yapabilen 1D-CAE tabanlı denetimsiz öğrenme sisteminin tasarım, uygulama ve ilk test süreçleri başarıyla tamamlanmıştır. Ara rapor aşamasına kadar olan süreçte; veri seti analizleri, gürültü bastırma stratejileri ve derin öğrenme mimarisi yapılandırılarak modelin eğitim safhası verimli bir şekilde gerçekleştirilmiştir. Proje hedeflerinin gerçekleşme oranı açısından bakıldığında; sistem tasarımı, metodoloji geliştirme ve model eğitimi aşamalarının %100 oranında tamamlandığı, nihai performans optimizasyonu safhasına ise başarıyla gelindiği görülmektedir.

Elde edilen ara sonuçlar, modelin sağlıklı kalp ritmi morfolojisini yüksek sadakatle öğrendiğini ve AF patolojilerini normal ritimlere kıyasla 2,73 kat daha yüksek bir hata payıyla (MSE) ayırt edebildiğini kanıtlamıştır. Denetimsiz bir yaklaşım olmasına rağmen ulaşılan 0,7714'lük AUC skoru, projenin en özgün kısmını oluşturan "etiket bağımsız teşhis" hipotezini matematiksel olarak doğrulamıştır. Sonuç olarak, bu aşamaya kadar elde edilen çıktılar; önerilen yöntemin giyilebilir sağlık teknolojileri için ölçeklenebilir, düşük maliyetli ve yüksek genelleme kapasitesine sahip bir teşhis altyapısı sunduğunu güçlü bir şekilde göstermektedir. Projenin nihai aşamasında gerçekleştirilecek olan hiperparametre iyileştirmeleri ve veri temizleme boru hattı (pipeline) entegrasyonu ile sistemin teşhis hassasiyetinin klinik standartlara yaklaştırılması hedeflenmektedir.

KAYNAKLAR

- [1] M. Rowen, "Atrial Fibrillation Signal Dataset," Kaggle, 2024. Erişim: [Atrial Fibrillation Signal Dataset](#)
- [2] S. Kiranyaz, T. Ince ve M. Gabbouj, "Real-time patient-specific ECG classification by 1-D convolutional neural networks," *IEEE Transactions on Biomedical Engineering*, cilt 63, no. 3, ss. 664-675, 2016.
- [3] A. Y. Hannun ve ark., "Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep convolutional neural network," *Nature Medicine*, cilt 25, no. 1, ss. 65-69, 2019.
- [4] P. Rajpurkar ve ark., "Cardiologist-level arrhythmia detection with convolutional neural networks," *arXiv preprint arXiv:1707.01836*, 2017.
- [5] J. Zhai ve ark., "Automated feature extraction for atrial fibrillation detection from ECG signals based on deep learning," *Journal of Medical Systems*, cilt 44, ss. 1-12, 2020.
- [6] O. Faust ve ark., "Deep learning for healthcare applications based on physiological signals: A review," *Computer Methods and Programs in Biomedicine*, cilt 161, ss. 1-13, 2018.
- [7] T. Schlegl, P. Seeböck, S. M. Waldstein, U. Schmidt-Erfurth ve G. Langs, "Unsupervised anomaly detection with generative adversarial networks to guide marker discovery," *International Conference on Information Processing in Medical Imaging*, ss. 146-157, 2017.
- [8] A. Isin ve S. Ozdalgı, "Cardiac arrhythmia detection using deep learning," *Computer Methods and Programs in Biomedicine*, cilt 142, ss. 45-49, 2017.
- [9] S. Chauhan ve L. Vig, "Anomaly detection in ECG time signals via deep long short-term memory networks," *IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, ss. 1-7, 2015.
- [10] Q. Mao ve ark., "A denoising autoencoder-based method for ECG signal enhancement," *IEEE Access*, cilt 8, ss. 71113-71121, 2020.
- [11] M. Thill ve ark., "Temporal autoencoders for anomaly detection in multivariate time series," *Proceedings of the 11th International Conference on Agents and Artificial Intelligence*, 2019.