

Üretken Yapay Zekaya Giriş

Dr. Öğr. Üyesi Elif DEĞİRMENCI

Otokodlayıcı Tabanlı Sistem Aracılığıyla Elektrokardiyogram Sinyallerinden Atriyal Fibrilasyon Tespiti

Grup Üyeleri:

Emre ALAYBEYOĞLU - 152120211160

Şevval Ayça ÇERENCE - 152120211128

Grup No:17



Giriş ve Motivasyon

Atrial Fibrilasyon Nedir?

Kalp ritminin morfolojik olarak düzensizleştiği kronik bir kardiyak aritmdir.

Dünya genelinde milyonlarca insanı etkileyen ve hızla yaygınlaşan bir sağlık sorunudur.

Zamanında teşhis edilemezse:

- İnme riski
- Kalp yetmezliği
- Kardiyovasküler kaynaklı ölüm riski

Neden Denetimsiz Öğrenme ?

Giyilebilir cihazlardan elde edilen devasa veri hacmi manuel analizi imkânsız kılmaktadır. Bu yöntem hem zaman alıcı hem de insan hatasına açıktır.

Denetimli modellerin iki temel kısıtı:

- Yüksek maliyetli uzman etiketleme ihtiyacı
- Gürültülü gerçek dünya verisinde performans düşüşü

Denetimsiz yaklaşımın avantajları:

- Etiket bağımlılığını tamamen ortadan kaldırır
- Sadece sağlıklı veriyle eğitim – anomaliyi yeniden inşa hatası üzerinden tespit
- Giyilebilir sağlık teknolojileriyle doğrudan entegrasyon

İlgili Çalışmalar

Araştırmacı(lar)	Yaklaşım	Katkı & Sınırlama
Kiranyaz ve ark. (2016)	1B Evrişimli Sinir Ağı	- Hasta özgü sınıflandırmada yüksek başarı - Etiketli veri bağımlı
Hannun & Rajpurkar (2019)	Derin CNN / ResNet	- Kardiyolog seviyesi tanı - Büyük ölçekli etiketli veri gerektirir
Faust ve ark. (2018)	Uzun Kısa Vadeli Bellek Ağı	- Zamansal bağımlılık yakalama - Gürültülü veriyle sınırlı performans
Chauhan & Vig (2015)	LSTM Otokodlayıcı	- Anomali tespitinde umut verici - Yalnızca küçük veri setleri
Schlegl ve ark. (2017)	Üretken Çekişmeli Ağ (AnoGAN)	- Denetimsiz anomali tespiti - Hesaplama maliyeti yüksek
Mao ve ark. (2020)	Gürültü Giderici Otokodlayıcı	- Sinyal kalitesini artırır - Sınıflandırıcı değil, ön işleyici

Literatürdeki mevcut çalışmalar yüksek başarı oranlarına ulaşsa da uzman onaylı etiketli veri setlerine bağımlıdır

Bizim Yaklaşımımız

Literatürdeki Kısıtlar

- Büyük çaplı uzman etiketli veri zorunluluğu
- Klinik ortamda sınıf dengesizliği problemi
- Giyilebilir cihaz gürültüsüne karşı kırılganlık
- Otokodlayıcılar yalnızca yardımcı araç olarak konumlandırılmış (özellik çıkarıcı veya gürültü temizleyici)
- Doğrudan anomali tespitine odaklanan denetimsiz birincil sınıflandırıcı yok

Bu Çalışmanın Özgünlüğü

- 1 Boyutlu Evrişimli Otokodlayıcı (1D-CAE): Doğrudan birincil sınıflandırıcı olarak tasarlandı.
- Yalnızca sağlıklı ve etiketsiz veri ile eğitim
- Yeniden inşa hatası metriği anomali kararının tek dayanağı
- Gürültülü giyilebilir cihaz sinyallerine uygun dinamik eşik optimizasyonu
- 4.826.817 parametrelili derin mimari ile güçlü genelleme kapasitesi

Metodoloji

Atrial Fibrilasyon Sinyal Veri Seti - Kaggle

20.000 Eğitim Sinyali

10.000 Test Sinyali

400 Hz Örneklem Hızı

10 sn Segment Uzunluğu

Sinyal Ön İşleme – Z-Skoru Normalizasyonu

- Her sinyal segmenti kendi ortalamasından çıkarılıp standart sapmasına bölünür.
- Sonuç: Ortalama = 0, Standart Sapma = 1
- Geleneksel ölçeklendirme tekniklerine kıyasla gürültü ve aykırı değerlere karşı daha dirençlidir.
- Model, genlik varyasyonları yerine morfolojik sapmalar üzerine odaklanır.

Anomali Tespiti Mantığı

Eğitim:

Yalnızca normal sinüs ritmine sahip kayıtlarla sağlıklı kalp morfolojisini öğrenir.

Test:

Tüm sinyaller modele beslenerek ortalama karesel hata bazlı yeniden inşa performansı hesaplanmaktadır.

Karar:

Hata > 0,0632 eşik değeri → Atrial Fibrilasyon (Anomali)

Optimum Eşik Değeri: 0,0632

Mimari Tasarım – 1 Boyutlu Evrişimli Otokodlayıcı

Kodlayıcı (Encoder) – 5 Katman

- Giriş: Ham elektrokardiyogram sinyali (4000 örneklem $\times$ 1)
- 5 ardışık 1B evrişim katmanı
- Her katmanda: Toplu Normalizasyon (Batch Normalization) + Leaky ReLU ($\alpha=0,2$)
- Hiyerarşik öznitelik sıkıştırma
- Çıkış: 64 boyutlu gizli temsil

Gizli Uzak (Latent Space)

64 boyutlu sıkıştırılmış temsil – kalp ritminin öz karakteristiklerini yakalar

Kod Çözücü (Decoder) – 5 Simetrik Katman

- Transpoze evrişim katmanları ile orijinal boyuta kademeli geri dönüş
- Her katmanda Toplu Normalizasyon

4.826.817


Eğitilebilir
Parametre

64

Gizli Uzak
Boyutu

5 + 5


Encoder +
Decoder Katmanı



Eğitim Stratejisi

Eğitim Konfigürasyonu

Optimizasyon Algoritması	Adam Optimizer
Kayıp Fonksiyonu	Ortalama Karesel Hata (MSE)
Örnekleme Hızı	400 Hz
Segment Uzunluğu	10 saniye (4.000 örneklem)
Eğitim Veri Seti	20.000 sinyal (yalnızca normal)
Erken Durdurma	43. eğitim döneminde
Eğitim Stratejisi	Sıfırdan eğitim (from scratch)



Modelin 43 epoch boyunca eğitim ve doğrulama MSE eğrisi

Stabilizasyon Mekanizmaları

- EarlyStopping: Aşırı öğrenmeyi engellemek için doğrulama kaybı izlendi
- ReduceLROnPlateau: Öğrenme durduğunda öğrenme oranı otomatik düşürüldü
- Verimli toplu iş yönetimi ile bellek tüketimi kontrol altına alındı, mini-batch stratejisi ile darboğazlar önleildi.

Ara Sonuçlar ve Bulgular

0,0561

Normal Sinüs Ritmi
Ortalama Yeniden İnşa Hatası

0,1533


Atriyal Fibrilasyon
Ortalama Yeniden İnşa Hatası

2,73×

Hata Oranı Farkı
(AF / Normal)

0,0632

Optimum
Eşik Değeri




Normal ve AF sinyallerinin MSE dağılımı ve belirlenen karar eşik değeri
(Threshold=0.063)

Temel Bulgular

- ▶ Model, normal sinüs ritmine özgü P-dalgası ve QRS kompleksini yüksek sadakatle yeniden oluşturabilmektedir.
- ▶ Atriyal fibrilasyon sinyallerinde P-dalgası kaybı ve kaotik f-dalgaları, modelin öğrendiği normal dağılıma uymadığından yeniden inşa hatası belirgin biçimde yükselmektedir.
- ▶ İki sınıf arasındaki istatistiksel ayrışma 2,73 katlık hata farkıyla net biçimde gözlemlenmektedir.
- ▶ Dinamik eşik değeri optimizasyonu yanlış pozitif oranını minimize etmiştir.

Başarı Metrikleri – ROC Analizi ve Sınıflandırma Performansı



AF tespiti için oluşturulan ROC eğrisi ve AUC skoru

Performans Özeti

AUC Skoru	0,7714
Optimum Eşik Değeri	0,0632
AF Hata Oranı / Normal Hata Oranı	2,73x

Sonuçların Değerlendirilmesi

- ROC-AUC metriği, sınıf dengesizliğine duyarsız yapısıyla anomali tespiti için en uygun değerlendirme ölçütüdür.
- 0,7714'lük skor, herhangi bir etiket kullanmadan tamamen denetimsiz bir yaklaşımla elde edilmiştir.
- Bu sonuç, 'etiket bağımsız teşhis' hipotezini matematiksel olarak doğrulamaktadır.
- Denetimli modeller daha yüksek doğruluk sunsa da önerilen yöntem etiketleme maliyetini tamamen ortadan kaldırır.

Tartışma ve Gelecek Çalışmalar

Mevcut Zorluklar

Paroksizmal Atriyal Fibrilasyon Problemi

Bazı sinyal segmentleri normal sinüs ritmine çok yakın morfoloji sergilediğinden modelin ayırt gücü kısıtlanmaktadır.

Gürültü Etkisi

Giyilebilir cihaz kaynaklı yoğun gürültü, sağlıklı sinyallerdeki yeniden inşa hatasını yapay olarak yükseltebilmektedir.

Yapısal Bozulma Odağı

Mevcut evrişimli mimari, sinyali anlık öznitelikler üzerinden başarılı bir şekilde modellerken; uzun dönemli zamansal değişimleri yakalama noktasında geliştirilmeye açıktır.

Gelecek Çalışma Planı

1

Hiperparametre Optimizasyonu

Gizli uzay boyutu, katman derinliği ve öğrenme oranı kombinasyonları sistematik biçimde test edilecek.

2

LSTM Tabanlı Hibrit Mimariler

Zamansal dinamikleri daha hassas yakalamak için Uzun Kısa Vadeli Bellek ağlarıyla hibrit tasarım denenecek.

3

Varyasyonel Otokodlayıcı Mimarisi

Veri dağılımını daha esnek modelleyebilen Varyasyonel Otokodlayıcı ile performans karşılaştırması yapılacak.

4

Otomatik Veri Temizleme Boru Hattı

19.000 etiketsiz kaydı entegre etmek için gürültü seviyesi yüksek verileri eleyen otomatik bir sistem kurulacak.

Sonuçlar

Doğrulanmış Hipotez

Denetimsiz öğrenme yaklaşımıyla 0,7714 AUC skoru elde edilerek etiket bağımsız teşhis hipotezi matematiksel olarak doğrulandı.

Güçlü Ayırt Edici Güç

Atrial fibrilasyon sinyallerindeki yeniden inşa hatası normal sinyallere kıyasla 2,73 kat daha yüksek seyretmektedir.

Ölçeklenebilir Altyapı

Düşük hesaplama maliyeti ve etiket bağımsız yapısıyla giyilebilir sağlık teknolojileriyle doğrudan entegre edilebilir.

Gelişim Yolu

LSTM hibrit mimariler ve Varyasyonel Otokodlayıcı ile klinik standartlara yaklaşılması hedeflenmektedir.

Teşekkürler...